8月18日

学习笔记

e2e: 端到端: 端到端是网络连接。网络要通信,必须建立连接,不管有多远,中间有多少机器,都必须在两头 (源和目的)间建立连接,一旦连接建立起来,就说已经是端到端连接了,即端到端是逻辑链路,这条路可能经过 了很复杂的物理路线,但两端主机不管,只认为是有两端的连接,而且一旦通信完成,这个连接就释放了,物理线路可能又被别的应用用来建立连接了。TCP就是用来建立这种端到端连接的一个具体协议,SPX也是。

hadoop、hbase、zookeeper关系

hadoop是分布式系统的一个文件系统,主要有3部分分别是hdfs, yarn, mapreduce

hdfs hdfs是hadoop管理储存的实现。 hdfs概念 数据块:就像单机系统(一台PC)上的数据块一样,提供磁盘读写的最小单位,也就是磁盘读某个数据时会把改块的数据一次性全部读入。不过单机系统上的数据块大小为512字节,hdfs数据块大小为128MB。 namenode和datanode:分布式系统储存和单机储存另一个不同就是,读取/写入某个数据时,分布式系统需要确定这个数据放在哪个主机。这也是namenode和datanode解决的问题。 namenode储存着这些文件的具体位置(具体在哪个主机和哪个块)和元数据(文件的一些属性),datanode是hdfs的工作结点,负责储存并检索数据块。因为namenode如果损坏后整个系统就不能使用,所以为了高可用性secondnamenode出现了,它相当于namenode的副本。

Hbase是一个面向列族的存储器,即Hbase在存储的时候将所有的列族成员都一起放在<u>HDFS</u>中存储,存储图片的数据比较大,图片的元数据比较少,所以分成两个列族来储存。

zookeeper的一个应用场景:有一组服务器提供某种服务,我们希望客户端都能找到其中一台服务器,然后我们需要维护这组服务器的成员列表,这个列表不能在某个服务器上,来避免单点故障,并且如果某个服务器出现故障,那么就需要从列表中删除改节点。这个场景不是一个被动的分布式结构,它能够在某个外部事件发生主动的修改数据结构,zookeeper提供的就是这种服务。下面介绍它是如何实现这种应用的。

flink官网: https://nightlies.apache.org/flink/flink-docs-release-1.10/zh/flinkDev/ide setup.html

flink github学习项目: https://github.com/zhisheng17/flink-learning

spark和flink的区别

- 1) 设计理念
- 1、Spark的技术理念是使用微批来模拟流的计算,基于Micro-batch,数据流以时间为单位被切分为一个个批次,通过分布式数据集RDD进行批量处理,是一种伪实时。
- 2、Flink是基于事件驱动的,是面向流的处理框架, Flink基于每个事件一行一行地流式处理,是真正的流式计算. 另外他也可以基于流来模拟批进行计算实现批处理。
- (2) 架构方面
- 1、Spark在运行时的主要角色包括: Master、Worker、Driver、Executor。
- 2、Flink 在运行时主要包含: Jobmanager、Taskmanager和Slot。
- (3) 任务调度

- 1、Spark Streaming 连续不断的生成微小的数据批次,构建有向无环图DAG,根据DAG中的action操作形成job,每个job有根据窄宽依赖生成多个stage。
- 2、Flink 根据用户提交的代码生成 StreamGraph,经过优化生成 JobGraph,然后提交给 JobManager进行处理, JobManager 会根据 JobGraph 生成 ExecutionGraph,ExecutionGraph 是 Flink 调度最核心的数据结构, JobManager 根据 ExecutionGraph 对 Job 进行调度。

(4) 时间机制

- 1、Spark Streaming 支持的时间机制有限,只支持处理时间。使用processing time模拟event time必然会有误差,如果产生数据堆积的话,误差则更明显。
- 2、flink支持三种时间机制:事件时间,注入时间,处理时间,同时支持 watermark 机制处理迟到的数据,说明 Flink在处理乱序大实时数据的时候,更有优势。

(5) 容错机制

- 1、SparkStreaming的容错机制是基于RDD的容错机制,会将经常用的RDD或者对宽依赖加Checkpoint。利用SparkStreaming的direct方式与Kafka可以保证数据输入源的,处理过程,输出过程符合exactly once。
- 2、Flink 则使用两阶段提交协议来保证exactly once。

(6) 吞吐量与延迟

- 1、spark是基于微批的,而且流水线优化做的很好,所以说他的吞入量是最大的,但是付出了延迟的代价,它的延迟是秒级;
- 2、而Flink是基于事件的,消息逐条处理,而且他的容错机制很轻量级,所以他能在兼顾高吞吐量的同时又有很低的延迟,它的延迟能够达到毫秒级;

心得

重大故障管理规程

目的:明确重大故障定义、规范重大故障处理流程,知道故障发生部门及时进行故障的分析与定位给、及时回复生产、并对故障进程复盘、排查、分析,降低故障发生频率,追求生产系统领故障,提升生产效率。

《重大故障管理规程》是为了明确重大故障定义、规范重大故障处理流程,知道故障发生部门及时进行故障的分析与定位给、及时回复生产、并对故障进程复盘、排查、分析,降低故障发生频率,追求生产系统领故障,提升生产效率。这门课程中也提到了项目成员、项目负责人等角色在发生故障之后,需要做的事情。故障紧急,是一个紧急预案,学习这门课程可以在关键时刻给予一个标准化的处理流程。因为在紧急时刻,人都是慌慌张张,脑子一热,大脑一片空白,根本不知道应该接下来做什么。在发生故障超过一定时间没有进行处理的,做出动作的,将纳入考核,这是对我们的一种激励,以免出现不作为的现象。这门课的学习,告诉了我公司系统出现重大故障的时候应该怎么做,做什么,怎么样做才能做到最好。这门课程中,关于出现重大问题的各种措施,我一定牢记心中,尽我最大的努力做到零故障,即使出现了故障,也要尽最大的努力,快速做出反应,给公司,给客户的损失降到最少,甚至没有。

生产运营违规(13类问题)讲解

《生产运营违规(13类问题)》这门课讲解了在我们日常的上班过程中,经常出现的问题。作为一名思特奇人,应 当诚实守信,忠于职守。在这13类问题中,处罚的条目都是涉及到诚实守信、忠于职守的问题。比如请假领不住、 法定节假日领补助、外出申请带考勤。带考勤肯定是员工不诚实守信,虚假报工,领补助和法定节假日领补助也一 样,没有工作,却欺骗公司自己工作了,需要发放补助。又比如报工重复,报工不足等问题,自己干的工作不上 报,或者说改做的工作没有完成才会出现这类问题,那么这肯定是不忠于职守的表现。这门课程,规范了我的行 为,用实际的例子,和应有的处罚规范我,提醒我在日常工作中的行为规范,教会了我如果做一名非常优秀、非常规范的思特奇人。

生产操作规程

经过在公司近一个月的学习,我了解到了生产操作规范的重要性。在这门课程中,我学到了生产环境的操作流程、动作的规范性。这让我了解到了在生产环境中应当注意什么,做什么。比如常规在linux认为正常的不能再正常的操作,在生产环境的时候要格外的注意,不能用kill、mv、vi等。在这门课程中,我还学到了不同生产账号的作用,了解到了项目经理,运营组织等角色在生产环境中的职责,扮演的角色。这能使我在今后的工作中,遇到自己没有权限,解决不了的问题的时候,可以找对应的负责人解决问题。之后,又学到了生产账号的申请,课程中强调了生产账号管理和使用原则,虽然我现在还没有生产账号,但正是因为提前学习,了解使用方法,才能在将来的工作中,不出错不掉链子,全心工作。学习此门课程,最大的感悟就是,在生产环境中,要小心再小心,遇到问题立马上报,切不可自己做觉得,以免给公司造成不可挽回的损失。